

TRƯỜNG ĐẠI HỌC BÁCH KHOA HÀ NỘI

Môn: Xử lý Ngôn ngữ Tự nhiên — Bài tập lớn

PHÂN TÍCH CẢM XÚC THEO KHÓA CẢNH

ABSA VLSP 2018 Hotel

Tài liệu hướng dẫn chi tiết — Dành cho người mới học NLP

Deadline: 21/04/2026

CHAPTER 1 — BÀI TOÁN LÀ GÌ?

1.1 Câu chuyện thực tế

Bien là quản lý chuỗi khách sạn. Mỗi ngày có hàng trăm đánh giá mới. Bien cần biết: khách hàng đang khen gì, chê gì, cần tìm kiếm khía cạnh nào?

Phương pháp	Tần suất	Chi tiết
Công cụ công	100 review/ngày	Cao nhưng không scale
Sentiment phân gien	Vài review/giây	Chỉ biết tổng thể positive/negative
ABSA (bài này)	Vài review/giây	Biết chính xác từng khía cạnh

1.2 Sentiment Analysis phân gien vs ABSA

Phương pháp	Input	Output
Sentiment phân gien	"Phòng sạch nhưng nhân viên thái độ kém"	NEGATIVE (chỉ biết tổng thể)
ABSA (bài này)	"Phòng sạch nhưng nhân viên thái độ kém"	ROOMS#CLEANLINESS → positive SERVICE#GENERAL → negative

Tại sao ABSA hữu ích hơn?

Sentiment phân gien cho biết review 'xấu' nhưng không biết XẤU Đâu. ABSA cho biết chính xác phòng tốt nhưng dịch vụ kém → quản lý biết cần cải thiện gì.

1.3 Hai nhiệm vụ chính trong ABSA

Nhiệm vụ	Viết tắt	Câu hỏi
Aspect Category Detection	ACD	Review có đề cập aspect X không?
Sentiment Polarity Classification	SPC	Nếu có, cảm xúc là positive/negative/neutral?

1.4 Nhận và ý nghĩa

Giá trị	Nhãn	Nghĩa	Ví dụ
0	absent	Không đề cập	Review về phòng → SERVICE#GENERAL = 0
1	positive	Đề cập và khen	"Phòng sạch" → ROOMS#CLEANLINESS = 1
2	negative	Đề cập và chê	"Dịch vụ tệ" → SERVICE#GENERAL = 2

3	neutral	■■ c■p, không rõ	"Phòng bình th■■ng" → ROOMS#COMFORT = 3
---	---------	------------------	---

CHAPTER 2 — TUẦN 1: PHÂN TÍCH KẾT QUẢ EDA

2.1 Dataset tổng quan

Split	Số reviews	Mục đích
Train	3,000	Đào tạo model học
Dev (Validation)	2,000	Điều chỉnh hyperparameters
Test	600	Đánh giá cuối — chỉ dùng 1 lần

Quy tắc quan trọng

Test set CHỈ được dùng 1 lần cuối. Nếu xem test trong lúc train thì điều chỉnh model → 'data leakage' → kết quả không đáng tin.

2.2 Phát hiện 1 — Độ dài Review → MAX_SEQ_LEN = 384

Split	p50 (trung vị)	p99 (99% ngắn hơn)
Train	~30 từ	243 từ
Dev	~20 từ	159 từ

Cách tính MAX_SEQ_LEN:

```
p99 = 243 từ
× 1.5 (word segmentation tạo thêm subword tokens)
= 364.5 → làm tròn lên bởi số 64 = 384

Nếu dùng 256 (default): ~10% reviews bị cắt mất phần cuối
Nếu dùng 384 (từ EDA): ~1% reviews bị cắt → ít mất thông tin hơn
```

Đánh đổi (Trade-off)

MAX_SEQ_LEN=384 cần ~50% VRAM hơn so với 256. Giải pháp: giảm batch_size 16→8, thêm gradient_accumulation=2, effective batch vẫn = 16.

2.3 Phát hiện 2 — Aspect Presence Rate

Top 5 phân biệt nhất (Train):

Rank	Aspect	Presence Rate	Ý nghĩa
------	--------	---------------	---------

1	SERVICE#GENERAL	~63%	Ng...i Vi...t hay bình lu...n v... d...ch v... nh...t
2	HOTEL#GENERAL	~43%	Nh...n xét t...ng quan khách s...n
3	LOCATION#GENERAL	~41%	V... trí r...t quan tr...ng
4	HOTEL#COMFORT	~40%	S... tho...i mái
5	ROOMS#DESIGN&FEATURES;	~30%	Thi...t k..., ti...n nghi phòng

Bottom 5 hi...m nh...t — C...n chú ý ...c bi...t:

Rank	Aspect	Presence Rate	V...n ...
34	ROOM_AMENITIES#PRICES	~0%	NGHIÊM TR...NG: 0 m...u có nhãn 1/2/3 trong train
33	ROOM_AMENITIES#MISCELLANEOUS	~0%	Ch... có nhãn 2 (negative)
32	ROOMS#MISCELLANEOUS	~0%	Ch... có nhãn 2 (negative)
31	FOOD&DRINKS;#MISCELLANEOUS	~0%	C...c k... hi...m
30	FACILITIES#MISCELLANEOUS	~1-2%	Ch... có negative

■ Phát hi...n nghiêm tr...ng nh...t

ROOM_AMENITIES#PRICES: 0 m...u positive/negative/neutral trong 3000 reviews train. T...t c... 3000 rows ...u = 0 (absent). Model s... không bao gi... h...c ...c aspect này → ACD F1 = 0. X... lý: Gi... trong model (output nh...t quán), LO...I kh...i Macro-F1 khi báo cáo, gi...i thích rõ lý do.

2.4 Phát hi...n 3 — M...t cân b...ng nhãn (Class Imbalance)

T...ng s... ô nhãn = 3,000 reviews × 34 aspects = 102,000 ô

Nhãn	Class	S... l...ng	T... l...	Weight global	Sau clip=10
0	absent	~87,000	85.3%	1.00	1.00
1	positive	~12,000	11.8%	8.61	8.61
2	negative	~2,500	2.4%	27.96	10.00
3	neutral	~500	0.5%	154.48	10.00

■ T...i sao weight=154 nguy hi...m và c...n clip?

Weight 154 làm gradient tăng 154 lần khi sai neutral → gradient explosion → training mất 1 tuần. Clip thời 10.0: model vẫn chú ý neutral nhiều hơn absent (10× vs 1×), nhưng không mất kiểm soát.

2.5 Preprocessing Pipeline — 5 Bước

Bước	Tên	Vấn đề giải quyết	Hậu quả nếu bỏ
1	Unicode NFC	Cùng char ' ' có 2 cách encode	2 token khác nhau cho 1 char
2	Whitespace	Newline, tab thừa từ web	Noise không cần thiết
3	Teencode	ko→không, sv→dịch vụ, nv→nhân viên	PhoBERT tokenize thành [UNK]
4	Special chars	@#\$%^ và ký tự lạ	Noise trong embedding
5	Word segment	nhân viên → nhân_viên	Mất ngữ nghĩa, giảm ~1-2% F1

Gap: underthesea thay VnCoreNLP

VnCoreNLP (dùng trong SOTA) cần Java 8+ và model ~200MB — không khả dụng. Dùng underthesea làm fallback. Chất lượng kém hơn ~1-2% F1. → Đây là 1 trong các lý do gap với SOTA. BKT BUOC ghi rõ trong báo cáo.

CHAPTER 3 — TUNING 2: TRAIN PHOBERT

3.1 PhoBERT và Fine-tuning

Khái niệm	Giải thích ngắn gọn
Pre-training (đã xong)	VinAI deploy PhoBERT 'hiệu' tiếng Việt từ 20GB text — không cần làm lại
Fine-tuning (bắt làm)	Deploy thêm PhoBERT bài toán ABSA cần thêm 3000 reviews
Tổng thể	Thuê chuyên gia tiếng Việt (PhoBERT), đào tạo thêm với lĩnh vực khách sạn

3.2 Kiến trúc Model

```
INPUT: "Phòng rỗng, nhân_viên thân_thiện"

Block 1 – Tokenization → input_ids [batch=8, max_len=384]
Block 2 – PhoBERT → 13 hidden states [batch, 384, 768]
Block 3 – Concat 4 layers cuối lại [CLS]:
    → [batch, 3072] ← KHÔNG phải 768
Block 4 – Dropout(0.2) → 34 × Linear(3072, 4)

OUTPUT: 34 nhãn ∈ {0, 1, 2, 3}
```

Tại sao concat 4 layers thay vì chỉ layer cuối?

Layers	Học được gì	Móng góp
Layer 1-4 (thấp)	Cú pháp, từ vựng	Biết 'sách' là tính từ
Layer 5-8 (giữa)	Ngữ nghĩa cơ bản	Biết 'sách' mang nghĩa tích cực
Layer 9-12 (cao)	Ngữ nghĩa phức tạp, hàm ý	Biết ngữ cảnh quy định hành vi
Concat 4 cuối	Có cả 3 loại trên	F1 cao hơn ~1-2% so với cls_only

3.3 Hyperparameters

Tham số	Giá trị	Lý do chọn
MAX_SEQ_LEN	384	Từ EDA: p99=243 × 1.5 → 384
batch_size	8	T4 16GB + seq_len=384 → OOM nếu 16
grad_accumulation	2	Effective batch = 16 (nếu batch=16 thì cần ít VRAM)
learning_rate	2e-5	Chuẩn cho fine-tuning BERT
warmup_ratio	0.1	Đặt LR từ 0 trong 10% steps đầu, tránh phá vỡ PhoBERT
weight_clip	10.0	Clip weight norm 154→10, tránh gradient explosion

dropout	0.2	Regularization, giảm overfitting
early_stop_patience	3	Dừng nếu dev F1 không tăng 3 epochs liên tiếp
max_grad_norm	1.0	Gradient clipping

3.4 Learning Curve — Bật buớc trong báo cáo

Thầy yêu cầu bật buớc: vẽ learning curve VÀ giải thích tại sao dừng epoch đó.

Màu cón giải thích	Nội dung
Train loss giảm dần	→ Model đang học tốt
Dev loss bắt đầu tăng từ epoch X	→ Overfitting bắt đầu từ epoch X
Early stopping dừng epoch X+3	→ Lấy checkpoint tốt nhất (epoch X)
Combined F1 plateau/giảm từ epoch X	→ Model không cải thiện thêm trên dev set
Khoảng cách với SOTA	→ Giải thích 5 nguyên nhân bên dưới

3.5 Kết quả k vng và giải thích Gap với SOTA

Metric	K vng	SOTA Paper	Gap
ACD F1	0.70–0.76	0.8255	~6-12%
SPC F1	0.62–0.68	—	—
Combined F1	0.66–0.72	0.7732	~5-11%

Kết quả trong khoảng này là BÌNH THƯỜNG — không phải lỗi code

Lý do gap	nh hng c tính	Giải thích
underthesea thay VnCoreNLP	~1-2%	SOTA dùng VnCoreNLP chính xác hơn
ROOM_AMENITIES#PRI CES = 0 mẫu	~0.5-1%	ACD F1 = 0 cho aspect này
Neutral c c hi m (clip=10)	~1-2%	SPC neutral thấp m m i aspect
Dataset nh (3000 train)	~1-2%	SOTA có thể dùng data augmentation
1 run, không ensemble	~0.5%	Ensemble nhiều seeds n nh h n
Tng c tính	~4-8%	Phù hợp gap thực tế

CHAPTER 4 — TUẦN 3: LLM FEW-SHOT VÀ RAG

4.1 Ý tưởng cốt lõi

Câu hỏi nghiên cứu

Câu hỏi 1 (Tuần 2): LLM với vài ví dụ có thể làm ABSA tốt không — không cần train? Câu hỏi 2 (Tuần 3): Chọn ví dụ thông minh hơn (RAG) có cải thiện F1 không?

4.2 Tuần 2 — In-Context Learning (ICL)

```
[System] Bạn là chuyên gia phân tích review khách sạn.  
[Ví dụ 1 – k=2]  
Review: "Phòng sạch, dịch vụ tuyệt vời"  
Output: {"ROOMS#CLEANLINESS": "positive", "SERVICE#GENERAL": "positive"}  
[Ví dụ 2]  
Review: "Nhân viên kém, giá đắt"  
Output: {"SERVICE#GENERAL": "negative", "HOTEL#PRICES": "negative"}  
[Test]  
Review: "Khách sạn đẹp nhưng xa trung tâm"  
Output: ??? ← GPT/Gemini tự suy luận từ ví dụ
```

Tham số k = số examples trong prompt. Thường $k=2, k=4, k=8$. Nhiều ví dụ $\rightarrow$ context tốt hơn $\rightarrow$ F1 thường cao hơn.

4.3 Tuần 3 — RAG (Retrieval-Augmented Generation)

Bước	ICL (Tuần 2)	RAG (Tuần 3)
Chọn examples	NGẫu NHIÊN từ train set	Tìm examples GIỐNG NHẤT với review test
Khoảng cách	<code>random.sample(train, k)</code>	Cosine similarity với sentence embeddings
Model embedding	—	keepitreal/vietnamese-sbert
Kiểm định F1	Baseline	Cao hơn ICL ~1-3%

So sánh fair

Tuần 2 vs Tuần 3: Cùng LLM + Cùng k + Cùng prompt format $\rightarrow$ Cải thiện F1 = đóng góp từ quá trình retrieval.

4.4 Khả năng kết quả

Phương pháp	Khả năng F1	Ghi chú
GPT-4o-mini ICL k=2	~0.55-0.62	Ít ví dụ, random
GPT-4o-mini ICL k=8	~0.60-0.68	Nhiều ví dụ nhất
GPT-4o-mini RAG k=4	~0.62-0.70	Examples liên quan hơn
Gemini 1.5 Flash	Thấp hơn GPT ~3-5%	Model nhỏ hơn GPT-4o-mini
PhoBERT (Tập 1)	~0.66-0.72	Tốt nhất, có 3000 training examples

CHAPTER 5 — TÓNG KẾT VÀ CHECKLIST

5.1 Bảng tổng kết toàn diện

Tuần	Nội dung	Chạy ở đâu	Output	Trạng thái
1	EDA, Preprocessing, DataLoader, Eval	Mac local	class_weights.json, preprocessed CSV	■ DONE
2	PhoBERT training, learning curve	Colab/Kaggle T4	best_model.pt, learning_curve.png	■ Đang chạy
3	LLM few-shot + RAG, 12 experiments	Mac local	week3_comparison.md	■ Chờ
4	Báo cáo, slides, nlp	Mac local	Báo cáo cuối	■ Chờ

5.2 Kết quả F1 tổng thể

Phương pháp	ACD F1	Combined F1	So với SOTA
SOTA (Huynh et al. 2022)	82.55%	77.32%	Tham chiếu
Tổng 1: PhoBERT ours	70-76%	66-72%	-5 điểm -11%
Tổng 2: LLM few-shot best	—	60-68%	-9 điểm -17%
Tổng 3: RAG best	—	62-70%	-7 điểm -15%

5.3 Checklist báo cáo cuối kỳ

Phần lý thuyết (phải có):

- Mô tả bài toán ABSA: ACD + SPC là gì, 34 aspects
- Tại sao dùng F1 thay Accuracy (giải thích class imbalance)
- Giải thích mất cân bằng nhãn và cách xử lý (weighted loss + clip)
- Kiến trúc PhoBERT multi-task (vì sao vậy)
- ICL, RAG và Chain-of-Thought là gì

Phần thực nghiệm (phải có):

- Learning curve (train/val loss + F1 theo epoch) — BẮT BUỘC THEO YÊU CẦU THỰC
- Giải thích overfitting xảy ra ở epoch nào — BẮT BUỘC
- Ablation: concat_4_layers vs cls_only
- Biểu đồ so sánh 3 tổng + SOTA với số F1 thực tế
- Biểu đồ ICL vs RAG theo k (k=2, 4, 8)

Phần phân tích (phải có):

- Gi¶i thích gap v¶i SOTA: ít nh¶t 3 nguyên nhân c¶ th¶ có s¶ li¶u
- Per-aspect F1: aspect nào model làm t¶t/kém và t¶i sao
- K¶t lu¶n RAG có hi¶u qu¶ không, t¶i sao
- Khi nào nên dùng PhoBERT supervised, khi nào dùng LLM

■ Ghi nh¶ quan tr¶ng nh¶t

K¶t qu¶ th¶p h¶n SOTA không ph¶i th¶t b¶i. ■i¶u quan tr¶ng là B¶N HI¶U T¶I SAO và có th¶ gi¶i thích rõ ràng t¶ng nguyên nhân v¶i s¶ li¶u c¶ th¶.

— H¶t tài li¶u —